

# MÉTODOS DE SEGMENTACIÓN

K. Guarín

University of Los Andes

gk.guarin10@uniandes.edu.co

## Abstract

*La segmentación de imágenes juega un papel muy importante en visión artificial o visión por computador, donde los objetivos principales son poder crear súper píxeles para extraer objetos hasta llegar a satisfacer las necesidades o metas del observador. Hasta el día de hoy se han estudiado diferentes métodos en los que se incluyen el agrupamiento de las imágenes digitales, ya sea mediante la utilización de clúster que asocian semejanzas de los píxeles o mediante la jerarquía estimando con el nivel de gris, tono o luminancia interpretado como la altitud del relieve en una imagen. En este trabajo se realizó la implementación de 3 técnicas de segmentación de imágenes digitales, utilizando diferentes espacios de color, y luego se evaluaron los métodos propuestos y se compararon con métodos avanzados. Se encontró que para la función planteada la técnica de gmm aplicada a un espacio lab proporciona un mejor IDS (optimal image scale) y ODS(optimal dataset scale) que las demás técnicas propuestas.*

**Palabras clave:** segmentación, k-means, gmm, watershed, hsv, lab, precisión, cobertura.

## 1. Introducción

La visión artificial como ciencia de la computación engloba diferentes técnicas para el procesamiento digital de imágenes, buscando día a día que los computadores puedan interpretar las imágenes como las perciben los seres humanos. Con el enorme momento del big data y la diversidad de aplicaciones en las que es necesario el uso de imágenes, es posible evidenciar como el estudio de diferentes técnicas de segmentación y en general de procesamiento de imágenes se ha acrecentado. Los algoritmos de segmentación generalmente se basan en el análisis y procesamiento de una de dos propiedades básicas de los valores de intensidad: la discontinuidad(cambios abruptos en la intensidad) y similitud (regiones similares según un conjunto de criterios predefinidos). La segmentación de imágenes significa subdividir en regiones u objetos

para permitir de una u otra forma “mejorar” una imagen para posteriormente ser analizada a profundidad y poder comprender los objetos en el campo de visión.

En la actualidad se han desarrollado variados métodos de segmentación para diferentes aplicaciones como la reconstrucción 3D de modelos anatómicos a partir de técnicas de clustering[Rodríguez et al., 1997], la implementación de watershed y fuzzy means para la segmentación y detección de patrones irregulares en imágenes de resonancia magnética[Ng et al., 2006] y la aplicación de la segmentación de imágenes de cartilago articular en osteoartritis[Fripp et al., 2010]. La variabilidad de aplicaciones en el campo de la biomédicina nos muestra la gran utilidad de la visión artificial y la importancia de entender y conocer las últimas metodologías para el procesamiento de las imágenes.

El presente trabajo muestra 3 métodos de segmentación de imágenes implementados en la base de datos de Berkeley.

### 1.1. Métodos

#### K-means

Es una de las técnicas de agrupamiento más simples usadas en la segmentación de datos e imágenes, cuyo objetivo principal es dividir elementos en grupos o clústers, donde cada elemento del grupo es similar a otro elemento del mismo grupo. El centroide es el valor o vector característico de cada grupo y representa el “centro” del grupo, dado que los grupos generalmente tienen forma circular.

$$\sum_{i=0}^k \sum_{x_j \in S_i} \|x_i - u_i\|^2 \quad (1)$$

*Algoritmo :*

1. Selecciona el número de grupos.
2. Asigna elementos a cada clúster.
3. Computa nuevos centroides.

4. Itera hasta obtener una estabilidad en las asignaciones.

### Gmm

Técnica basada en la representación de cada grupo como una distribución gaussiana; los clúster son formados por la representación de la función de densidad de probabilidad. La distancia de un punto a otro está dada por el cálculo de la distancia de Mahalanobis, lo cual permite que la distancia se adapte a la distribución de los datos.

$$\sum_k \pi_k \frac{1}{\sum_k} e^{-d(x, \mu_k; \Sigma_k)} \quad (2)$$

*Algoritmo :*

1. Seleccionar el número de grupos.
2. Asigna una densidad de probabilidad por grupo.
3. Calcula la distancia euclidiana.
4. Asigna responsabilidades a cada punto.
5. Itera hasta converger a un mínimo local.

### Watershed

Es una técnica de segmentación inspirada en las cuencas hidrográficas, donde la cuenca representa el conjunto de puntos en los que todas las gotas de lluvia convergen a la misma ubicación. las líneas del watershed separan dos cuencas. En imágenes el tono se interpreta como la altitud de relieve en una imagen y para calcular las cuencas se toman los mínimos regionales y se realiza la inundación hasta el nivel deseado.

*Algoritmo*

1. Se hace un agujero para cada mínimo regional de la superficie topográfica.
2. Se sumerge en agua poco a poco la superficie.
3. Se van formando lagos y cuando los lagos se encuentran se ubica una línea para evitar que los dos lagos se unan.
4. El conjunto de presas de agua son las cuencas.

## 1.2. Espacios de color

Las imágenes pueden ser representadas en tres espacios de color:

- RGB: Modelo basado en la síntesis de la mezcla por adición de los 3 colores primarios cian, magenta, amarillo y negro, además de sus tres componentes espectrales primarias (rojo verde azul).

- HSV: Se define como el color en términos de sus componentes, o transformación lineal del espacio rgb. Este espacio tiene en cuenta el tinte, saturación y valor.
- LAB: Modelo cromático para representar todos los colores que puede percibir el ojo humano. L es la luminosidad, a es variación entre rojizo y verdoso, y b la variación entre amarillo y azul.

## 2. Resultados

De los resultados obtenidos se muestran inicialmente las imágenes para el análisis de la clusterización mediante vecindades para diferentes espacios de color. En segunda medida se presentan resultados de los 3 métodos de segmentación implementados (k-means, gmm y watershed) para los tres espacios de color (rgb, hsv y lab). Por último se muestra los resultados a manera comparativa de la evaluación.

- Espacios de representación rgb, hsv, lab, rgb+xy, hsv+xy, lab+xy

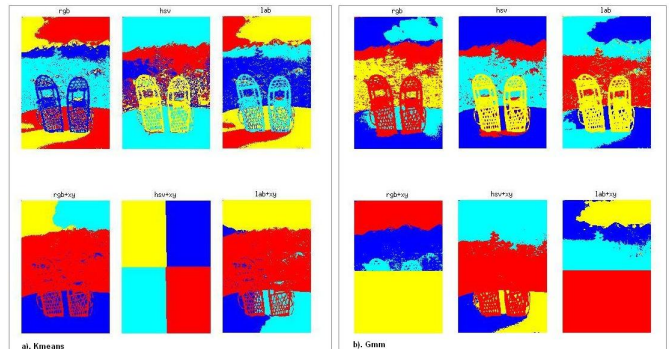


Figure 1. Espacios de color para k-means y gmm con mismo número de k

- Métodos de segmentación

En las figuras 2, 3, 4, 5 y 6 se presentan resultados de la segmentación para cada método en los diferentes espacios de color.

- Evaluación

Se implementó el código boundaryBench de Pablo Arbelaez < arbelaez@eecs.berkeley.edu > [Arbelaez et al., 2011], para evaluar las diferentes técnicas de segmentación propuestas y aplicadas a las las imágenes de test de la base de datos de berkeley. Como resultado se tiene la gráfica de precisión y cobertura para poder dar un estimado de qué tan bueno o malo es el método. Los resultados se encuentran en las figuras 7, 8, 9, 10 y 11.



Figure 2. Método kmeans y espacios de color para K=4

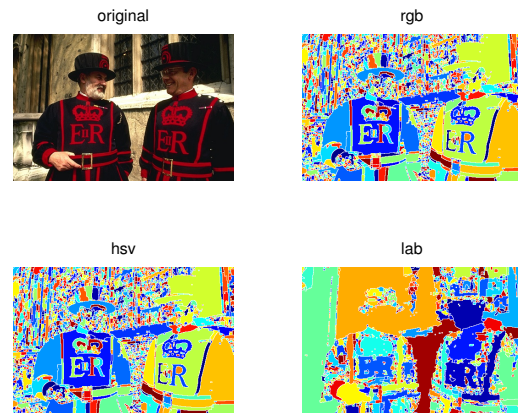


Figure 4. Método watershed y espacios de color con h=20.




Figure 3. Método Gmm y espacios de color para K=4




Figure 5. Método jerarquico y espacios de color con h=20.

### 3. Discusión

Al implementar la función de segmentación para los distintos espacios de representación de color, se observó que los espacios que involucran la posición espacial no proporcionan una mejor segmentación. Se esperaba que al incluir las posiciones xy estas dos variables aportaran información a los píxeles de color y así lograr obtener una segmentación sobre el color apoyada en el posicionamiento. Sin embargo, la segmentación se basó más en el posicionamiento que en los valores de color de la imagen, como se puede observar en la Figura 1 (parte superior es la segmentación sin tener en cuenta xy y la parte de inferior teniendo en cuenta xy), se pueden comparar los resultados de la segmentación y corroborar lo dicho anteriormente.

Durante la etapa de entrenamiento se observaron los resultados de las segmentaciones para los 4 métodos propuestos y se estimaron los rangos adecuados para implementar cada uno de los métodos. Para k-means y gmm se decidió que los valores adecuados están en un rango entre 2 a 16 (ejemplo: Figura 2 y 3 con k=4). Para el método jerárquico los valores se pueden estimar entre 2 a 30, sin embargo los resultados varían dependiendo de la imagen y no son muy buenos comparados con los de k-means y gmm (Figura 5 y 6). Para watershed los rangos se estimaron valores entre 20 a 90, pero a pesar de tener un rango amplio los resultados presentan sobresegmentación y a medida que se aumenta el nivel se pierden segmentos importantes como se evidencia en la Figura 4.

Es difícil decir que espacio de representación de color




Figure 6. Método jerarquico y espacios de color con  $h=10$ .




Figure 8. Evaluación de los espacios de color y gmm con la gráfica de precisión y cobertura.




Figure 7. Evaluación de los espacios de color y k-means con la gráfica de precisión y cobertura.

y qué técnica de segmentación es la mejor con solo el análisis visual. Por ello es necesario evaluar las distintas técnicas con un método de evaluación; en nuestro se usó caso boundari bench para obtener la gráfica de precisión-cobertura.

Para la evaluación de los resultados se analizó cada método de manera individual para estimar cuál espacio de color es el más oportuno para utilizar en la segmentación y como se puede observar en la Figura 7, para k-means los resultados de lab y rgb son muy parecidos y los resultados de hsv son un poco mejores, dado que maneja una precisión mayor que la de lab y rgb, y además presenta un rango mayor de cobertura aunque al final la cobertura es mayor




Figure 9. Evaluación de los espacios de color y watershed la gráfica de precisión y cobertura.

para lab. En el caso de gmm (Figura 8) el espacio hsv presenta peor rendimiento y rgb-lab siguen presentando características similares en la respuesta. Finalmente se evaluó watershed (Figura 9) encontrando un amplio rango de cobertura con lab y mayor precisión pero en ese instante la cobertura es mínima, en rgb se encontró la mayor cobertura de gmm.

En la Figura 10 se muestran los resultados simultáneos de la función propuesta y se observa que la gráfica roja que representa gmm-lab es aparentemente el mejor resultado, y la manera de comprobar esto es mediante la Tabla 1, que nos muestra medias estadísticas de las gráficas

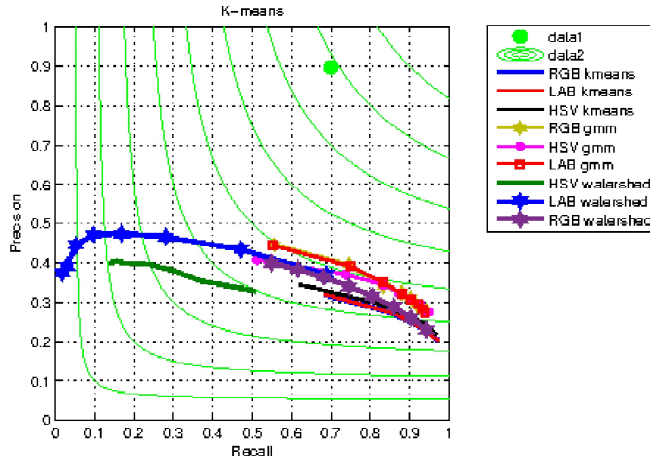


Figure 10. Gráfica comparativa de los resultados de la evaluación para los métodos propuestos.




Figure 11. Resultados de la evaluación de los métodos propuestos vs los métodos propuestos en el mundo.

consideradas como los mejores resultados para cada método. De esa manera es posible evidenciar que gmm-lab tiene el mayor ODS e IDS entendido como la escala optima para el conjunto de datos y la escala optima de imagen. Sin embargo al comparar los resultados obtenidos con los métodos propuestos con los mejores métodos desarrollados en el mundo[Arbelaez et al., 2011], se evidencia que la metodología propuesta se queda corta con lo que va hasta el momento en el mundo, como es el caso de gPb-owl-ucm con una alta cobertura y precisión.

| Method        | ODS  | OIS  | Área | th   |
|---------------|------|------|------|------|
| Watershed-lab | 0.48 | 0.51 | 0.29 | 1.1  |
| Gmm-lab       | 0.52 | 0.58 | 0.15 | 2.0  |
| Kmeans-hsv    | 0.44 | 0.49 | 0.1  | 1.30 |
| gPb-owl-ucm   | 0.73 | 0.76 | 0.73 | -    |

Table 1. Resultados de la mejor gráfica por método

## 4. Conclusiones

De los métodos mencionados anteriormente se puede inferir al visualizar los resultados de la segmentación que técnicas como watershed al manejar un mayor rango en los datos es posible tener una mayor precisión en algunos casos, en contraste con los métodos donde se toman pocos valores de agrupamiento y no muy diferenciables entre ellos.

Los resultados de segmentación incluyendo coordenadas no mejoran la clasificación de objetos. Por el contrario se enfocan más en la segmentación de cuadrantes.

A pesar de que gmm fue el método que tomó más tiempo que las demás técnicas en segmentar imágenes, los resultados fueron mejores en el espacio de color lab, por tanto, para proyectos básicos de segmentación se puede utilizar fácilmente un método como gmm-lab simple de implementar.

## References

- [Arbelaez et al., 2011] Arbelaez, P., Maire, M., Fowlkes, C., and Malik, J. (2011). Contour detection and hierarchical image segmentation. *Pattern Analysis and Machine Intelligence, IEEE Transactions on*, 33(5):898–916.
- [Fripp et al., 2010] Fripp, J., Crozier, S., Warfield, S., and Ourselin, S. (2010). Automatic segmentation and quantitative analysis of the articular cartilages from magnetic resonance images of the knee. *Medical Imaging, IEEE Transactions on*, 29(1):55–64.
- [Ng et al., 2006] Ng, H., Ong, S., Foong, K., Goh, P., and Nowinski, W. (2006). Medical image segmentation using k-means clustering and improved watershed algorithm. In *Image Analysis and Interpretation, 2006 IEEE Southwest Symposium on*, pages 61–65.
- [Rodríguez et al., 1997] Rodríguez, R., Fernández-Britto, J. E., Alarcón, T. E., Gusk, H., and Taylor, C. (1997). Métodos de segmentación de imagen aplicados a las lesiones arteriales: I. Comparación. *Revista Cubana de Investigaciones Biomédicas*, 16:58 – 62.